

Pipeline Riset dan Anatomi Big Data Publik

01 Lima tahap yang selalu ada

ASK	Merumuskan pertanyaan	Sesi 01-02
GET	Mengambil dan membersihkan	Sesi 03-04
EXPLORE	Menjelajah dan memvisualkan	Sesi 05-06
MODEL	Mengestimasi dan memvalidasi	Sesi 07-10
COMMUNICATE	Menerjemahkan jadi keputusan	Sesi 11-14

Kalau satu tahap dilewati, proyeknya gagal jauh setelahnya, saat memperbaikinya sudah mahal.

02

Aliran sebenarnya tidak satu arah

NORMAL DAN SEHAT

- 01 Sampai di Explore, menemukan variabel kunci hanya tersedia lima tahun
- 02 Kembali mempersempit pertanyaan
- 03 Mengganti sumber data setelah tahu keterbatasannya

BERBAHAYA

- 01 Memaksakan pertanyaan awal pada data yang tidak mampu menjawabnya
- 02 Menyembunyikan ketidakcocokan itu di bagian metodologi
- 03 Menemukannya saat penguji bertanya di Sesi 15

Pertanyaan riset yang buruk
tidak bisa diselamatkan
oleh metode secanggih apa pun.

ASK

03 Empat syarat pertanyaan yang bisa dikerjakan

Spesifik

Jelas siapa, di mana, dan kapan

Terukur

Variabelnya punya definisi operasional yang bisa ditemukan datanya

Feasible

Selesai dalam empat belas minggu dengan data yang benar-benar ada

Relevan

Jawabannya mengubah sesuatu untuk seseorang

Syarat ketiga yang paling sering dilanggar. Ambisi besar di Sesi 02 berubah jadi panik di Sesi 08.

04 Bandingkan keduanya

BURUK

"Bagaimana pengaruh digitalisasi terhadap perekonomian Indonesia?"

Tidak jelas apa itu digitalisasi, perekonomian yang mana, periode kapan.

BISA DIKERJAKAN

"Apakah perluasan jaringan 4G di kabupaten-kabupaten di Jawa antara 2015 dan 2019 meningkatkan jumlah usaha mikro terdaftar?"

Ada unit analisis, periode, variabel perlakuan, dan variabel hasil. Masalah identifikasinya juga langsung terlihat: menara tidak dibangun secara acak.

05 Dirancang versus organik

DIRANCANG

- 01 Survei, sensus, eksperimen
- 02 Kerangka sampel diketahui
- 03 Kecil, mahal, lambat
- 04 Kamu tahu siapa yang diwakilinya

ORGANIK

- 01 Transaksi, pencarian, jejak lokasi, citra satelit
- 02 Tidak ada kerangka sampel
- 03 Besar, cepat, murah
- 04 Kamu tidak tahu siapa yang hilang darinya

Ukuran sampel yang besar
tidak memperbaiki bias seleksi.
Ia hanya membuat estimasi yang bias
terlihat lebih presisi.

Konsep terpenting di materi ini

06 Tiga jalur pengambilan data

-
- | | | |
|---|------------------|--|
| A | API | Pintu resmi dari penyedia. World Bank, FRED, Google Earth Engine. Paling rapi dan paling bisa diulang. |
| B | Unduhan langsung | Berkas CSV di tautan tetap. Our World in Data dan sebagian data BPS. |
| C | Web scraping | Pilihan terakhir. Perhatikan syarat layanan situs dan etika pengambilannya. |
-

07 Pembersihan memakan porsi terbesar

01 Nama kabupaten berbeda ejaan antar sumber

02 Kode wilayah berubah karena pemekaran

03 Nilai hilang yang bukan nol

04 Satuan yang tidak konsisten

05 Periode yang tidak berimpit

Tidak ada jalan pintas.

Yang ada hanya dokumentasi yang rapi, sehingga kamu bisa menjelaskan setiap keputusan pembersihan tiga bulan kemudian saat penguji bertanya.

Empat pertanyaan tahap EXPLORE

Bentuk sebaran

Bagaimana distribusi variabel utama kamu?

Nilai ekstrem

Apa yang terjadi di ekor, dan apakah itu kesalahan data?

Patahan tren

Adakah patahan yang bertepatan dengan perubahan kebijakan?

Bentuk hubungan

Apakah hubungan antar variabel terlihat linier?

Jawabannya menentukan spesifikasi model. Melewati tahap ini berarti memilih model dengan menebak.

09 Pertanyaan menentukan model

Hubungan pada satu titik waktu, variasi antar unit sudah cukup

OLS

Unit yang sama diamati berkali-kali, ada karakteristik tetap tak teramati

Panel Fixed Effects

Variabel penjelas dipengaruhi balik oleh variabel hasil

Variabel Instrumen / 2SLS

Kebijakan berlaku pada sebagian unit di waktu tertentu

Difference-in-Differences

Yang menentukan pilihan bukan selera, melainkan struktur data dan sumber ancaman terhadap validitas.

10 Estimasi pertama bukan hasil

YANG DIUJI

- 01 Statistik F tahap pertama untuk instrumen lemah
- 02 Uji tren paralel untuk DiD
- 03 Uji placebo
- 04 Ganti variabel kontrol
- 05 Ganti subsampel

Temuan yang runtuh ketika spesifikasi sedikit digeser bukan temuan.

Menemukan itu sendiri di Sesi 10 jauh lebih baik daripada penguji yang menemukannya di Sesi 15.

11 Dua produk, dua audiens

POLICY MEMO, 2 HALAMAN

- 01 Untuk orang yang harus memutuskan sesuatu
- 02 Tidak akan membaca tabel regresi kamu
- 03 Butuh tahu: apa temuannya, seberapa yakin, apa yang sebaiknya dilakukan
- 04 Sesi 12, bobot 15 persen

LAPORAN AKADEMIK

- 01 Untuk orang yang menilai apakah kamu layak dipercaya
- 02 Justru membaca tabel dan memeriksa asumsi identifikasi
- 03 Mencari lubang dalam argumen kamu
- 04 Sesi 14, bobot 10 persen

12 Lima V, dan asal-usul kerangkanya

Volume

Ukuran

Velocity

Kecepatan

Variety

Keragaman

Veracity

Kebenaran

Value

Nilai

Tiga yang pertama berasal dari catatan Doug Laney di Gartner tahun 2001. Sisanya ditambahkan belakangan oleh berbagai pihak, dan daftarnya terus bertambah sampai tujuh dan sepuluh V.

Pakai sebagai daftar periksa, bukan sebagai teori. Dua yang menentukan nasib proyek kamu: kebenaran dan nilai.

13 Kekuatan dan lubang tujuh sumber data

S U M B E R	K E K U A T A N	L U B A N G
Google Trends	Harian dan cepat	Indeks relatif, hanya pengguna internet
Google Mobility	Berguna untuk 2020-2022	Sudah dihentikan
Google Earth Engine	Resolusi geografis luar biasa	Waktu belajar yang nyata
World Bank	Lintas negara, rapi	Tahunan, banyak lubang untuk negara kecil
Our World in Data	Paling mudah, sudah dikurasi	Cakupan variabel terbatas
FRED	Sangat lengkap untuk deret waktu makro	Dominan data Amerika Serikat
BPS	Sampai tingkat kabupaten	Rilis lambat, format tidak ramah mesin

Proyek kamu wajib menggabungkan minimal dua sumber. Pikirkan sekarang pasangan mana yang masuk akal.

Setiap angka dalam laporan kamu harus bisa dihasilkan ulang orang lain dari kode dan datamu, tanpa bertanya kepada kamu.

Itulah alasan kita memakai GitHub sejak Sesi 03

Buka lab Colab.
Apa yang bisa dan
tidak bisa dijawab?

Sesi depan kamu menerima topik beserta datanya, dan menulis sendiri kalimat pertanyaan risetnya.